



**Міністерство освіти і науки України
Національний технічний університет
України
«Київський політехнічний інститут імені
Ігоря Сікорського»**

Лабораторна робота з криптографії

Експериментальна оцінка ентропії на символ джерела відкритого тексту

Виконали:

Студенти групи ФБ-33

Бондар Марина Вікторівна,

Романовська Крістіна Миколаївна

Перевірив:

к.ф.-м.н., ст. викл.
кафедри математичних
методів захисту
інформації Селюх П.В

Київ 2025

Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Порядок виконання роботи:

1. Написати програми для підрахунку частот букв і частот біграм в тексті, а також підрахунку H_1 та H_2 за безпосереднім означенням. Підрахувати частоти букв та біграм, а також значення H_1 та H_2 на довільно обраному тексті російською мовою достатньої довжини (щонайменше 1Мб), де імовірності замінити відповідними частотами. Також одержати значення H_1 та H_2 на тому ж тексті, в якому вилучено всі пробіли.

Для аналізу був обраний текст “Майстер і Маргарита” та записаний у файл Bulgakov_Mihail_Master_i_Margarita.txt

В подальшому програма буде зчитувати та аналізувати за допомогою функцій.

Усі отримані дані виконання скрипта були записані у таблицю “results.xlsx”

```
(venv) kristinaromanovska@MacBookAir lab1 % python3 lab1.py
```

Обробка

```
З ПРОБІЛАМИ
H1 : 4.37282
H2 (крок 1): 3.98246
H2 (крок 2): 3.98177
R (H1): 0.12544
R (H2 крок 1): 0.20351
R (H2 крок 2): 0.20365
```

```
БЕЗ ПРОБІЛІВ
H1 : 4.45071
H2 (крок 1): 4.14669
H2 (крок 2): 4.14651
R (H1): 0.10163
R (H2 крок 1): 0.16299
R (H2 крок 2): 0.16303
Результати збережено в файл.
```

Монограми

Монограми (з пробілами)

Монограми (без пробілів)

H_1 : 4.37282
 $R(H_1)$: 0.12544

Буква	Кількість	Частота
	113993	0,160041
о	66180	0,092913
а	51732	0,072629
е	48624	0,068265
и	40935	0,057470
н	38351	0,053843
т	36067	0,050636
л	31460	0,044168
с	30318	0,042565
р	28390	0,039858
в	28201	0,039592
к	21878	0,030715
у	17976	0,025237
м	17951	0,025202
п	17006	0,023875
д	16812	0,023603
г	11489	0,016130
я	11407	0,016014
ь	10820	0,015190
з	10632	0,014926

H_1 : 4.45071
 $R(H_1)$: 0.10163

Буква	Кількість	Частота
о	66180	0,110617
а	51732	0,086467
е	48624	0,081272
и	40935	0,068421
н	38351	0,064102
т	36067	0,060284
л	31460	0,052584
с	30318	0,050675
р	28390	0,047452
в	28201	0,047136
к	21878	0,036568
у	17976	0,030046
м	17951	0,030004
п	17006	0,028424
д	16812	0,028100
г	11489	0,019203
я	11407	0,019066
ь	10820	0,018085
з	10632	0,017770

Біграми, що перетинаються

Біграми крок 1 (з пробілами)

H2 (крок 1): 3.98246

R (H2 крок 1): 0.20351

	A	B	C
1	Біграма	Кількість	Частота
2	то	9705	0,016221
3	но	7071	0,011818
4	ст	6690	0,011182
5	на	6559	0,010963
6	по	6522	0,010901
7	ов	6474	0,010821
8	ал	6391	0,010682
9	не	6289	0,010511
10	ко	6135	0,010254
11	ро	5709	0,009542
12	ла	5539	0,009258
13	ен	5442	0,009096
14	го	5434	0,009082
15	ра	5388	0,009005
16	ос	5374	0,008982
17	от	5345	0,008933
18	он	5306	0,008868
19	ни	5188	0,008671
20	ка	5089	0,008506
21	ер	4901	0,008191
22	...	4885	0,008184

Біграми крок 1 (без пробілів)

H2 (крок 1): 4.14669

R (H2 крок 1): 0.1629

	A	B	C
1	Біграма	Кількість	Частота
2	о	15225	0,021375
3	а	12853	0,018045
4	п	12090	0,016973
5	в	11619	0,016312
6	и	11555	0,016222
7	е	11551	0,016217
8	н	10906	0,015311
9	с	10513	0,014759
10	то	9417	0,013221
11	и	7885	0,011070
12	но	6913	0,009705
13	о	6851	0,009618
14	к	6851	0,009618
15	я	6693	0,009396
16	ь	6636	0,009316
17	ст	6573	0,009228
18	по	6520	0,009153

Біграми, що не перетинаються

Біграми крок 2 (з пробілами)

H2 (крок 2): 3.98177

R (H2 крок 2): 0.20365

	A	B	C
1	Біграма	Кількість	Частота
2	о	7625	0,021410
3	а	6463	0,018147
4	п	5996	0,016836
5	и	5824	0,016353
6	е	5823	0,016350
7	в	5819	0,016339
8	н	5578	0,015662
9	с	5270	0,014797
10	то	4640	0,013028
11	и	3902	0,010956
12	но	3475	0,009757
13	о	3473	0,009751
14	к	3426	0,009619
15	ст	3395	0,009532
16	ь	3318	0,009316
17	я	3303	0,009274

Біграми крок 2 (без пробілів)

H2 (крок 2): 4.14651

R (H2 крок 2): 0.16303

	A	B	C
1	Біграма	Кількість	Частота
2	то	4794	0,016025
3	но	3593	0,012011
4	ст	3351	0,011202
5	ов	3298	0,011024
6	на	3253	0,010874
7	по	3206	0,010717
8	ал	3153	0,010540
9	не	3106	0,010383
10	ко	2973	0,009938
11	ро	2813	0,009403
12	ен	2761	0,009229
13	ла	2760	0,009226
14	ра	2760	0,009226
15	ос	2741	0,009162
16	го	2704	0,009039
17	от	2653	0,008868

Матриця біграм

Матриця біграм (з пробілами):

	а	б	в	г	д	е	ж	з	и	й	к	л	м	н	о	п
а	5,62E-06	0,000548	0,002507	0,000899	0,002234	0,001101	0,001085	0,003865	0,000293	0,000576	0,004246	0,008615	0,003097	0,005071	3,23E-05	0,000856
б	0,000952	1,12E-05	2,11E-05	1,83E-05	7,02E-06	0,002314	1,12E-05	1,4E-06	0,000658	0	0,000159	0,000567	4,49E-05	0,000316	0,001936	0
в	0,006328	1,12E-05	0,000111	1,97E-05	0,00027	0,005609	0	0,000413	0,003516	0	0,000232	0,000584	0,000117	0,000879	0,006291	0,000215
г	0,002135	0	2,81E-06	0	0,000899	0,000479	0	1,4E-06	0,000629	0	7,44E-05	0,001564	1,12E-05	0,000389	0,007597	0
д	0,004182	7,02E-05	0,000914	1,12E-05	1,12E-05	0,00385	5,19E-05	9,83E-06	0,00198	0	0,0003	0,00042	0,000129	0,001925	0,003252	0,000101
е	0,000131	0,000861	0,002081	0,002926	0,002805	0,00129	0,000758	0,001381	0,000199	0,001852	0,001412	0,005913	0,003642	0,006238	0,000194	0,001182
ж	0,001316	2,39E-05	0	1,4E-05	0,000716	0,002955	9,83E-06	0	0,001129	0	0,00014	4,07E-05	8,42E-06	0,000629	5,34E-05	0
з	0,005457	0,00017	0,001088	0,000272	0,000859	0,000628	8,7E-05	2,11E-05	0,00049	0	0,000112	0,000344	0,000234	0,001377	0,000647	0
и	0,000229	0,00056	0,002756	0,000489	0,001481	0,001651	0,000247	0,002189	0,000482	0,001617	0,00267	0,006127	0,002527	0,003228	0,000403	0,000296
й	0	9,83E-06	0	1,12E-05	9,97E-05	0	0	0	0	0	0,000121	1,26E-05	3,79E-05	0,000365	8,42E-06	0
к	0,007068	0	0,000539	0	0	0,000865	4,77E-05	1,54E-05	0,002881	0	2,25E-05	0,000806	2,81E-06	0,000674	0,008401	0
л	0,007506	7,86E-05	2,39E-05	0,000114	6,6E-05	0,004442	0,000212	2,95E-05	0,006225	0	0,000396	0,000427	5,34E-05	0,000459	0,006201	5,76E-05
м	0,003572	9,83E-06	6,88E-05	7,58E-05	0	0,003104	0	0	0,002799	0	0,000108	0,000181	8,42E-05	0,001262	0,002899	0,000171
н	0,009133	5,62E-06	2,95E-05	9,41E-05	0,000852	0,008787	1,12E-05	5,62E-05	0,007014	0	0,000258	0	0	0,003096	0,009706	0
о	8,42E-06	0,002972	0,006907	0,004324	0,004487	0,001526	0,00156	0,001474	0,000658	0,003806	0,002543	0,006229	0,00565	0,005284	0,000194	0,001341
п	0,001664	0	0	0	0	0,002121	0	0	0,001254	0	8,99E-05	0,000894	0	0,000254	0,000154	6,18E-05
р	0,007525	6,74E-05	0,000487	0,001011	0,000257	0,005598	0,000227	4,63E-05	0,005557	0	0,000396	0,000256	0,000195	0,000955	0,007911	6,32E-05
с	0,001664	7,02E-05	0,001476	2,67E-05	0,00025	0,002943	3,79E-05	1,83E-05	0,001797	0	0,003885	0,002464	0,000592	0,000861	0,002599	0,001608
т	0,005565	2,39E-05	0,001928	2,81E-06	0,00015	0,005697	0	4,21E-06	0,003424	0	0,000719	0,000212	2,81E-05	0,001245	0,013221	7,72E-05
у	0,000102	0,000635	0,000716	0,000928	0,001796	0,000174	0,001192	0,000278	2,11E-05	0,000146	0,000942	0,002183	0,000927	0,000496	4,21E-06	0,000615
ф	0,000272	0	0	0	0	0,000503	0	0	0,000334	0	0	8,84E-05	0	1,4E-06	0,000244	0
х	0,000567	1,4E-06	0,000166	5,76E-05	0	6,32E-05	0	0	0,000313	0	7,02E-06	0,000163	5,76E-05	0,000327	0,001776	0
ц	0,00063	0	6,32E-05	0	0	0,00083	0	0	0,000284	0	1,4E-05	5,62E-06	0	0	0,000257	0
ч	0,002242	0	1,4E-06	0	0	0,003782	0	0	0,001547	0	0,00049	2,53E-05	4,21E-06	0,000776	6,32E-05	0
ш	0,001018	0	6,46E-05	0	0	0,002054	0	0	0,001801	0	0,00039	0,000428	7,02E-06	0,00038	0,000241	4,77E-05
щ	0,000441	0	0	0	0	0,001244	0	0	0,001026	0	0	0	0	5,48E-05	4,21E-06	0

Матриця біграм (без пробілів):

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
а	б	в	г	д	е	ж	з	и	й	к	л	м	н	о	п	
а	0,000471	0,001422	0,005121	0,001707	0,003396	0,001747	0,001494	0,00521	0,001844	0,000687	0,006373	0,010682	0,004588	0,008172	0,001193	0,003435
б	0,001137	1,5E-05	4,35E-05	2,34E-05	1E-05	0,002758	1,5E-05	5,01E-06	0,000812	0	0,000197	0,000675	6,18E-05	0,000383	0,002337	1,84E-05
в	0,007615	0,000276	0,000623	0,000425	0,000605	0,006808	7,19E-05	0,000649	0,004451	3,34E-06	0,001135	0,000929	0,00047	0,00159	0,007966	0,0011
г	0,002557	3,01E-05	5,68E-05	1E-05	0,001096	0,00058	3,34E-06	4,51E-05	0,000812	0	0,000114	0,001867	2,67E-05	0,000506	0,009083	7,86E-05
д	0,005031	0,000127	0,001225	8,36E-05	6,02E-05	0,004618	6,52E-05	8,52E-05	0,002469	0	0,000485	0,000545	0,000234	0,002517	0,003933	0,000301
е	0,000446	0,001986	0,004429	0,003953	0,004	0,001792	0,001125	0,002345	0,001468	0,00221	0,002571	0,007426	0,00518	0,009096	0,001362	0,003619
ж	0,001566	4,68E-05	2,67E-05	2,17E-05	0,000866	0,003535	1,17E-05	1E-05	0,001366	0	0,000192	5,18E-05	1,84E-05	0,000796	8,36E-05	1,34E-05
з	0,00654	0,000261	0,001476	0,000389	0,001115	0,000766	0,000115	0,000152	0,000657	1,67E-06	0,000331	0,00044	0,000383	0,00184	0,000876	0,000242
и	0,000525	0,001404	0,005579	0,001157	0,00246	0,002283	0,000443	0,003279	0,001681	0,001926	0,004227	0,007637	0,003642	0,005653	0,001732	0,002576
й	0,000197	0,000394	0,000816	0,00043	0,000511	8,02E-05	0,000157	0,000236	0,00069	0	0,000839	0,000184	0,000478	0,001105	0,00046	0,001061
к	0,008506	0,000374	0,001172	0,000115	0,000125	0,001098	0,000181	0,000119	0,003828	0	0,000309	0,001036	0,000192	0,00127	0,010254	0,000438
л	0,009258	0,000495	0,00115	0,000425	0,000321	0,005634	0,000289	0,000219	0,008182	0	0,001148	0,000605	0,000374	0,001417	0,007889	0,001028
м	0,004376	0,000358	0,000928	0,000468	0,000323	0,003818	9,86E-05	0,000254	0,003983	0	0,000607	0,000418	0,000356	0,002282	0,004043	0,001117
н	0,010963	0,000192	0,000428	0,000194	0,001122	0,010512	5,18E-05	0,000209	0,008672	0	0,000478	3,84E-05	0,000107	0,00414	0,011819	0,000503
о	0,000303	0,004719	0,010821	0,005711	0,006196	0,002333	0,002285	0,002492	0,002216	0,004531	0,004249	0,007824	0,00762	0,008869	0,002078	0,004117
п	0,001982	3,34E-06	1,34E-05	1,67E-06	1,67E-06	0,002526	0	3,34E-06	0,001501	0	0,000109	0,001065	1,67E-06	0,000306	0,010901	7,52E-05
р	0,009006	0,000125	0,000747	0,001234	0,000364	0,006684	0,000277	9,03E-05	0,006947	0	0,000565	0,000329	0,000271	0,001322	0,009542	0,000284
с	0,002034	0,000249	0,002056	0,00017	0,000403	0,003555	0,000147	0,00012	0,002295	0	0,004943	0,002994	0,000824	0,001422	0,003251	0,00229
т	0,006776	0,000271	0,002975	0,00017	0,000373	0,00694	0,00017	0,000192	0,004583	0	0,001269	0,000398	0,000267	0,002138	0,016222	0,000779
у	0,000314	0,000991	0,001666	0,001244	0,002412	0,000304	0,001494	0,000506	0,000847	0,000174	0,001559	0,002701	0,001437	0,001524	0,000394	0,001534
ф	0,000324	1,67E-06	5,01E-06	0	1,67E-06	0,000598	1,67E-06	0	0,000401	0	1,67E-06	0,000105	0	8,36E-06	0,000299	3,34E-06
х	0,000752	0,00013	0,000485	0,00016	0,00015	0,000115	2,67E-05	0,000105	0,000654	0	0,000286	0,000304	0,000209	0,00066	0,0023	0,000443
ц	0,000757	1,67E-05	0,000115	1E-05	1,67E-05	0,000993	0	8,36E-06	0,000383	0	3,68E-05	1,17E-05	1E-05	3,68E-05	0,000341	4,51E-05
ч	0,002689	3,68E-05	6,35E-05	1,5E-05	1,34E-05	0,004505	1,67E-06	4,18E-05	0,001872	0	0,00061	4,68E-05	6,69E-06	0,000996	0,000124	8,02E-05
ш	0,001215	0	8,36E-05	3,34E-06	1,67E-06	0,002445	0	1,67E-06	0,002153	0	0,000465	0,000515	8,36E-06	0,000465	0,000291	7,19E-05
щ	0,000528	5,01E-06	5,01E-06	0	1,67E-06	0,001483	0	0	0,001224	0	3,34E-06	1,67E-06	0	6,52E-05	8,36E-06	5,01E-06

2. За допомогою програми CoolPinkProgram оцінити значення H^{10} , H^{20} , H^{30} .

Отже, після виконання завдання ми отримали результати для кожної ентропії n-грам.

1) H^{10}

$1,99978685929135 < H^{10} < 2,73602285566283$

[illegible]

2) H^{20}

$$1,59103562083877 < H^{20} < 2,39273078857449$$

The screenshot shows a software interface for a laboratory experiment on entropy. The window title is "Лабораторная работа №1".

Top Section:

- Произвольная часть текста:** A text input field containing "тен_законц_тяготения_и_не_может_пойти_против_него_если_вы_оставите_человека".
- Использованные буквы:** A text input field containing "_ , я, и,".

Left Panel (Order of n-grams):

- 5 символов
- 10 символов
- 15 символов
- 20 символов** (highlighted in blue)
- 25 символов
- 30 символов
- 35 символов
- 40 символов
- 45 символов
- 50 символов

Center Section:

- Введенный символ:** я
- Символ по счету:** 4
- Номер эксперимента:** 52
- Поле ввода символов:** я
- Buttons:** "Продолжить" and "Другой"

Right Panel (Entropy and Symbol Table):

- Неравенство для энтропии:** $1,59102562083877 < H < 2,39273078857449$
- Двоичная таблица угаданных символов:** A table with 32 rows and 2 columns. The first row is "00000000000000000000000000000000". The second row is "10000000000000000000000000000000". The third row is "10000000000000000000000000000000". The fourth row is "00000000000000000000000000000000". The fifth row is "10000000000000000000000000000000". The sixth row is "00000000000000000000000000000000". The seventh row is "00000000000000000000000000000000". The eighth row is "00000000000000000000000000000000". The ninth row is "00000000000000000000000000000000". The tenth row is "00000000000000000000000000000000". The eleventh row is "00000000000000000000000000000000". The twelfth row is "00000000000000000000000000000000". The thirteenth row is "00000000000000000000000000000000". The fourteenth row is "00000000000000000000000000000000". The fifteenth row is "00000000000000000000000000000000". The sixteenth row is "00000000000000000000000000000000". The seventeenth row is "00000000000000000000000000000000". The eighteenth row is "00000000000000000000000000000000". The nineteenth row is "00000000000000000000000000000000". The twentieth row is "00000000000000000000000000000000". The twenty-first row is "00000000000000000000000000000000". The twenty-second row is "00000000000000000000000000000000". The twenty-third row is "00000000000000000000000000000000". The twenty-fourth row is "00000000000000000000000000000000". The twenty-fifth row is "00000000000000000000000000000000". The twenty-sixth row is "00000000000000000000000000000000". The twenty-seventh row is "00000000000000000000000000000000". The twenty-eighth row is "00000000000000000000000000000000". The twenty-ninth row is "00000000000000000000000000000000". The thirtieth row is "00000000000000000000000000000000". The thirty-first row is "00000000000000000000000000000000". The thirty-second row is "00000000000000000000000000000000".

Bottom Section:

- Вероятности:** A list of 32 probabilities, each corresponding to a symbol in the binary table. The probabilities are: q[1] = 0,5576923; q[2] = 0,0961538; q[3] = 0,0769230; q[4] = 0,0576923; q[5] = 0,0384615; q[6] = 0,0576923; q[7] = 0; q[8] = 0,0192307; q[9] = 0; q[10] = 0,0192307; q[11] = 0; q[12] = 0; q[13] = 0; q[14] = 0; q[15] = 0; q[16] = 0; q[17] = 0; q[18] = 0; q[19] = 0,0192307; q[20] = 0; q[21] = 0; q[22] = 0,0192307; q[23] = 0; q[24] = 0; q[25] = 0; q[26] = 0; q[27] = 0; q[28] = 0,0192307; q[29] = 0,0192307; q[30] = 0; q[31] = 0; q[32] = 0.

Footer:

- Строка состояния:** Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка

3) H³⁰

Лабораторная работа №1

Произвольная часть текста:
ению_к_кому_не_следует_быть_э

Использованные буквы:

Порядок n-граммы:

5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 54

Поле ввода символов:

Продолжить

Другой

Неравенство для энтропии:
1,5588737710857 < H < 2,31006929672943

Двоичная таблица угаданных символов:
01000000000000000000000000000000
00010000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
~ ~ ~ ~ ~

Вероятности:

q[1] = 0,5471698
q[2] = 0,1509433
q[3] = 0,0566037
q[4] = 0,0566037
q[5] = 0
q[6] = 0
q[7] = 0,0377358
q[8] = 0
q[9] = 0,0188679
q[10] = 0,018867
q[11] = 0,056603
q[12] = 0
q[13] = 0,018867
q[14] = 0
q[15] = 0
q[16] = 0
q[17] = 0
q[18] = 0
q[19] = 0
q[20] = 0,018867
q[21] = 0,018867
q[22] = 0
q[23] = 0
q[24] = 0
q[25] = 0
q[26] = 0
q[27] = 0
q[28] = 0
q[29] = 0
q[30] = 0
q[31] = 0
q[32] = 0

Строка состояния:

Для виконання цього пункту, ми використали формули із матеріалів комп'ютерного практикуму:

Надлишковість джерела відкритого тексту (мови) дорівнює $R = 1 - \frac{H_{\infty}}{H_0}$

Оскільки в рос. алфавіті є 33 літери, за умовами задачі “Ё” та “Ъ” замінюємо на “Е” та “Ь”, пробіл вважаємо окремою літерою. У результаті ми отримали алфавіт, яким налічує 32 букви.

- H10

$$R_1 = 1 - \frac{1,99978685929135}{5} = 1 - 0.39995737185827 = 0.60$$

$$R_r = 1 - \frac{2,73602285566283}{5} = 1 - 0.54720457113257 = 0.45$$

$0.60 < H10 < 0.45$

• H20

$$R_l = 1 - \frac{1.59103562083877}{5} = 1 - 0.31820712416775 = 0.68179287583225 = 0.68$$

$$R_r = 1 - \frac{2.39273078857419}{5} = 1 - 0.47854615771490 = 0.52145384228510 = 0.52$$

$$0.68 < H_{120} < 0.52$$

• H30

$$R_l = 1 - \frac{1.5588737710857}{5} = 1 - 0.31177475421714 = 0.68822524578286 = 0.69$$

$$R_r = 1 - \frac{2.31006929672943}{5} = 1 - 0.46201385934589 = 0.53798614065411 = 0.54$$

$$0.69 < H_{30} < 0.54$$

Висновки: у ході виконання комп'ютерного практикуму, було досліджено ентропію та надлишковість рос. мови. За допомогою статичного аналізу скриптом, ми змогли застосувати навички визначення частот могограм, біграм. На основі цих роздахунків було отримано ентропію першого та другого порядку (монограм та біграм).

Експериментальна оцінка, яка була здійснена за допомогою програми CoolPinkProgram, продемонструвала, що метод вгадування наступних літер, зменшує ентропію із збільшенням порядку (H^{10} , H^{20} , H^{30})